

SAS と R における Firth 法の実装差の整理と数値的評価

SAS ユーザー総会 2026

西川寛来（協和キリン），後藤駿輔（ノバルティス ファーマ）

2026-10-15

本プレゼンテーションで述べられている見解および意見は発表者個人のものであり、その他の個人または組織の見解や意見を反映するものではありません。

背景・目的



完全分離と準完全分離

分離と呼ばれる状況では、通常の方法で有限の回帰係数を求めることができない。

完全分離

		イベント	
		あり	なし
曝露	あり	1	0
	なし	0	19

準完全分離

		イベント	
		あり	なし
曝露	あり	1	19
	なし	0	20

イベント有無が 2 群で分かれている。 イベントが曝露群にのみ存在

いずれも回帰係数が発散し、有限の最尤推定値が得られない。

Existence of Maximum Likelihood Estimates; Heinze & Schemper (2002)

小標本での推定のバイアスを低減し、分離下でも有限の回帰係数を求める方法

$$\ell_F(\beta) = \ell(\beta) + \frac{1}{2} \log |I(\beta)|$$

ℓ : 通常対数尤度、 I : Fisher 情報行列

- 罰則付き対数尤度 ℓ_F を最大化する
- モデル行列がフルランクなら、分離下でも有限の推定値が得られる

Firth (1993); Kosmidis & Firth (2021)

Firth 法によるバイアス低減の例

60 例、説明変数 3 個、真の係数 1、シミュレーション 2000 回とし、通常のロジスティック回帰と Firth 法を比較



この条件では、Firth 法によってバイアスが大きく低減している。

Kosmidis & Firth (2021)

Firth 法の信頼区間と検定

Wald 法、またはプロファイル罰則付き尤度（PL）に基づく方法を用いる。

Wald 法

$$Z = \frac{\hat{\beta}}{\text{SE}}$$

信頼区間： $\hat{\beta} \pm z_{1-\alpha/2} \text{SE}$

検定： $|Z| > z_{1-\alpha/2}$ なら棄却

PL 区間・罰則付き尤度比検定（PLRT）

$$\text{LR} = 2(\ell_{F,\text{full}} - \ell_{F,\text{restricted}})$$

ℓ_F ：罰則付き対数尤度

- full：全係数を推定
- restricted： β を固定して他を再推定

信頼区間： $\text{LR} \leq \chi^2_{1,1-\alpha}$ となる範囲

検定： $\beta = 0$ での $\text{LR} > \chi^2_{1,1-\alpha}$ なら棄却

logistf

SAS・RでFirth法を使うには

SASではPROC LOGISTICのFIRTHオプションや%FLマクロ、Rではパッケージが用意されている。

言語	形態	名称
SAS	プロシジャ	PROC LOGISTIC
SAS	公開マクロ	%FL (georgheinze/flicflac)
R	パッケージ	logistf
R	パッケージ	brglm2

MODEL Statement; flicflac; logistf; brglm2



CAMIS : Comparing Analysis Method Implementations in Software

SAS・Rにおける各統計手法の実装差を比較・検証するワーキンググループ

The screenshot shows the CAMIS website's 'Repository' page. The page has a navigation bar with links: About, Publications and Projects, Meeting Minutes, Blog, and Help. The main content area is titled 'Repository' and includes a description: 'The repository below provides examples of statistical methodology in different software and languages, along with a comparison of the results obtained and description of any discrepancies.' To the right of the main content, there is a sidebar titled 'On this page' with links: Introduction to CAMIS, Motivation, and Repository. The main content area contains a table with the following structure:

Statistical Methodology	R	SAS	Python	Comparison
Summary Statistics				
Rounding	R	SAS	Python	R vs SAS
Summary statistics	R	SAS	Python	R vs SAS
Skewness/Kurtosis	R	SAS	Python	R vs SAS
General Linear Models				
One-sample t-test	R	SAS	Python	R vs SAS
Paired t-test	R	SAS	Python	R vs SAS
Two-sample t-test	R	SAS	Python	R vs SAS
ANOVA	R	SAS	Python	R vs SAS
ANCOVA	R	SAS	Python	R vs SAS
MANOVA	R	SAS	Python	R vs SAS

CAMIS の報告：Firth 法の実装差と数値比較

CAMIS では、SAS PROC LOGISTIC と R logistf の実装差と実行結果を比較している。

- 既定では信頼区間・検定・計算アルゴリズム・収束設定も異なる。
- 両実装を PL 区間で揃え、`survival::lung` データを用いて解析すると、各共変量の点推定値・95% 信頼区間は小数第 3 位まで一致した。
- 一方、age の標準誤差や p 値では出力結果の数値に差があった。

R vs SAS: Logistic Regression

- CAMIS の報告では、分離への対処を必要としないデータを用いている。
- 分離が生じやすい小標本では、信頼区間・検定・最適化・収束基準の違いが結果に大きく影響する可能性がある。

小標本・少数イベントの状況で、SAS と R の実装差が結果の違いにどの程度影響するかを評価する。

実装の違いの整理



実装	既定の信頼区間	既定の検定	切り替え方法
SAS PROC LOGISTIC	CLPARM で指定	Wald 検定	p 値は変更不可
SAS %FL	PL 区間	PLRT	pI で Wald 区間・検定
R logistf	PL 区間	PLRT	pI で Wald 区間・検定
R brglm2	Wald 区間	Wald 検定	本発表では Wald 法を使用

MODEL Statement; logistf; brglm2; LogisticRegression/fl.sas

標準誤差の計算方法

PROC LOGISTIC · %FL · brglm2 では、通常の情報行列を使う。

$$I = \sum_i w_i x_i x_i^T, \quad \hat{V} = I^{-1}$$

logistf では、補助重みを加えた情報行列を使う。

$$I_{\text{aug}} = \sum_i w_i (1 + h_i) x_i x_i^T, \quad \hat{V} = I_{\text{aug}}^{-1}$$

$w_i = \hat{p}_i(1 - \hat{p}_i)$ 、 $\hat{p}_i$ ：推定確率

x_i ：説明変数ベクトル、 $\hat{V}$ ：分散共分散行列

$h_i = w_i x_i^T I^{-1} x_i$ ：観測 i の当てはめへの影響度

Iterative Algorithms for Model Fitting; logistf C source

点推定の計算アルゴリズムと収束基準

実装	計算アルゴリズム	反復上限	収束基準
SAS PROC LOGISTIC	Fisher scoring	25 回	相対勾配 $\leq 10^{-8}$
SAS %FL	修正スコアに 基づく更新	50 回	係数の変化量の合計 $\leq 10^{-4}$
R logistf	Newton–Raphson	25 回	尤度変化・最大絶対スコア ・係数変化 $\leq 10^{-5}$
R brglm2	quasi Fisher scoring	100 回	次の係数更新量の最大値 $< 10^{-6}$

PROC LOGISTIC は Newton 法に切替可
logistf は IRLS（反復再重み付き最小二乗法）に切替可
4 実装とも回数・収束基準は変更可

Iterative Algorithms for Model Fitting; LogisticRegression/fl.sas; logistf; brglm2

サンプルコード：SAS PROC LOGISTIC と %FL

PROC LOGISTIC

```
proc logistic data=dat;  
  model y(event='1') = exposure  
    / firth clparm=pl alpha=0.05;  
run;
```

MODEL Statement; LogisticRegression/fl.sas

%FL

```
%include "fl.sas";  
%fl(data=dat, y=y,  
  varlist=exposure,  
  pl=1, pl1=1, alpha=0.05,  
  outtab=fltab);
```

サンプルコード : R logistf と brglm2

logistf : PL 区間・PLRT

```
fit_lf <- logistf::logistf(  
  y ~ exposure, data = dat,  
  firth = TRUE, pl = TRUE,  
  alpha = 0.05)  
summary(fit_lf)
```

logistf; brglm2

brglm2 : Wald 区間・Wald 検定

```
fit_bg <- glm(y ~ exposure,  
  data = dat, family = binomial(),  
  method = brglm2::brglmFit,  
  control = brglm2::brglmControl(  
    type = "AS_mean")) # Firth 法を指定  
summary(fit_bg)  
confint(fit_bg, level = 0.95)
```

数値実験の方法

1. 分割表

- 説明変数は曝露のみの 2×2 表
- 総症例数 20・50・100・200 例、群配分 1:1・1:4
- 各群のイベント数を 0 から動かし、 2×2 表で考え得るすべての組み合わせを評価

2. 共変量モデル

- 説明変数は曝露と連続共変量 2 個
- 40 例 (20:20)・100 例 (20:80)
- 非曝露群のイベント確率 0.05、真のオッズ比 2
- 共変量間の相関は 0・0.5・0.9・0.99
- 各条件 2,500 回の繰り返し

異なる 2 つの実装に対して、判定差と数値差を指標として評価する。

対象	判定差	数値差
95% 信頼区間	一方だけが 0 を含む	下限・上限の差で大きい方
p 値	一方だけが $p < 0.05$	差の絶対値

分割表は各組み合わせを 1 件、共変量モデルは各データを 1 件として数える。

設定を変更した比較

既定の設定から変更し、信頼区間・p 値への影響を調べる。

設定	変更内容
信頼区間・検定	信頼区間：Wald 区間 $\leftrightarrow$ PL 区間 検定：Wald 検定 $\leftrightarrow$ PLRT
計算アルゴリズム	PROC LOGISTIC：Fisher scoring $\leftrightarrow$ Newton 法 logistf：Newton–Raphson $\leftrightarrow$ IRLS
点推定の収束条件	収束基準・反復上限を変更
信頼区間の収束条件	収束基準・反復上限を変更

収束判定を厳しくしたときの比較

実装	引数・判定する値	閾値	既定	厳しい数値設定	
			反復上限	閾値	反復上限
SAS PROC LOGISTIC	GCONV：相対勾配	10^{-8}	25	10^{-12}	5,000
SAS %FL	epsilon：係数変化の絶対値の和	10^{-4}	50	10^{-12}	5,000
logistf 点推定	lconv：対数尤度の変化	10^{-5}	25	10^{-12}	5,000
	gconv：スコアの最大絶対値				
	xconv：係数変化の最大絶対値				
logistf PL 区間	lconv：目標対数尤度とのずれ	10^{-5}	100	10^{-12}	200
	xconv：係数変化の最大絶対値				
brglm2	epsilon：次の係数更新量の最大絶対値	10^{-6}	100	10^{-12}	5,000



MODEL Statement; logistf.control; logistpl.control

結果



信頼区間の設定を揃えたときの結果：PL 区間



各群 25 例で対数オッズ比の信頼区間が 0 を含むか判定した。



今回の設定では、Wald 区間から PL 区間に揃えるとすべての判定が一致した。

信頼区間の設定を揃えたときの結果：Wald 区間


各群 25 例で Wald 区間に設定し、信頼区間が 0 を含むか判定した。



今回の比較では、Wald 区間に揃えても標準誤差の計算方法の違いにより判定差が残った。

総症例数を変えた結果

群配分 1:1・1:4 とし、総症例数を変えて比較した。



今回の全列挙では、総症例数が増えるほど判定が異なった割合は低下した。


群配分を変えた結果

PROC LOGISTIC の Wald 区間 対 logistf の PL 区間
群配分 1:1・1:4 とし、各群の症例数を変えて比較した。

総症例数	各群の症例数 (1:1)	判定差	各群の症例数 (1:4)	判定差
20 例	10 対 10	10.08%	4 対 16	12.05%
50 例	25 対 25	5.34%	10 対 40	6.68%
100 例	50 対 50	2.08%	20 対 80	3.53%
200 例	100 対 100	0.69%	40 対 160	1.70%

今回の 4 条件では、総症例数が同じ場合に群配分 1:4 の方が判定差の割合は高かった。


共変量モデルでの信頼区間の判定差



今回の 8 条件では、共変量の相関が高くなるほど判定差が増える傾向は見られなかった。

要因別の影響：信頼区間の数値差

どの要素を変更すると差が大きくなるかの比較を行った。



考察



SAS・Rの各実装で異なる要素

信頼区間・検定： %FL・logistf は PL 法と Wald 法を切り替えられる。本発表で用いた brglm2 の出力は Wald 法である。

PROC LOGISTIC は信頼区間を変更できるが、検定は Wald のみ使用できる。

標準誤差： PROC LOGISTIC・%FL・brglm2 は通常の情報行列、logistf は補助重みを加えた情報行列を用いる。

計算アルゴリズム： 実装ごとに異なる。PROC LOGISTIC は Newton 法、logistf は IRLS へ変更できる。

収束判定： 収束基準・閾値・反復回数は実装ごとに異なり、それぞれ変更できる。

MODEL Statement; logistf; brglm2; LogisticRegression/fl.sas

結論：実装差の主な要因と比較時の確認事項

- 今回の比較では、Wald 法か PL 法かという信頼区間・検定方式の違いが、数値差の大きな要因だった。
- Wald 法に揃えても、標準誤差の計算方法の違いにより判定を変えることがあった。
- 計算アルゴリズムや収束設定にも差があり、同じ方式でも数値や収束状態が異なり得る。

まず推論方式を揃え、Wald 法では標準誤差の定義も確認する。さらに、点推定・区間計算それぞれの収束設定と実際の収束状態を確認する。

Appendix



判定が異なった組み合わせの数値差

各群 25 例で、PROC LOGISTIC の Wald 区間と logistf の PL 区間の判定が異なった組み合わせを比較した

PROC LOGISTIC 対 logistf	中央値	最大値
Wald 区間 対 PL 区間	0.412	1.899
PL 区間 対 PL 区間	0.00000790	0.0000290

同じ 36 表で数値差は小さくなったが、完全には一致しなかった

判定が異なった表の例

曝露群：25 例中イベント 6 例、非曝露群：25 例中イベント 1 例

実装	信頼区間
PROC LOGISTIC (Wald)	−0.214863 — 3.603990
logistf (PL)	0.019542 — 4.016196
PROC LOGISTIC (PL)	0.019526 — 4.016199

PL 区間に揃えると下限がともに 0 を上回り、判定が一致した

$$\text{logit}(p_i) = \alpha_\rho + \log(2) \text{exposure}_i + 0.5x_{1i} + 0.5x_{2i}$$

$$x_1, z \sim N(0, 1), \quad x_2 = \rho x_1 + \sqrt{1 - \rho^2} z$$